



Examen Data Exploration - ING1 GI

2 feuilles R/V manuscrites autorisées, Calculatrice autorisée

Date : 22 décembre 2023

Durée : 2h

Nombre de pages : 6

Il sera tenu compte de la qualité de la rédaction et de la précision des justifications.

◊ ◊ ◊

Exercice 1

Le jeu des données Airbnb se compose d'informations publiques sur les annonces et les mesures Airbnb à New York. Les données ouvertes Airbnb de la ville de New York 2019 comprennent des informations sur environ 28590 logements Airbnb dans la ville et sont mises à la disposition du public par le gouvernement de la ville de New York pour promouvoir la transparence et la compréhension de l'impact des locations sur la ville. Dans la suite, on prendra que les 500 premiers logements et voici un extrait :

ID	Neighbourhood	Latitude	Longitude	Room type	Price\$	Minimum night	Number of reviews	Availability
2539	Brooklyn	40.64747	-73.9724	Private room	125	5	149	324
2595	Manhattan	40.15792	-73.5896	Entire home	225	3	45	194
3647	Brooklyn	40.76489	-73.965	Shared room	53	15	21	49
...


- Préciser les variables étudiées, donner leur type et un moyen de les représenter graphiquement
- Quelle est la population étudiée ? Quelle est la taille de l'échantillon ?

A- Analyse Univariée : Étude de la variable prix (en dollars)

Le logiciel R nous fournit les résultats suivants :

```
>quantile (Airbnb$price)
0%   25%   50%   75%   100%
33    85    125    186    2000
```

- Donner et interpréter les quartiles.
- Calculer l'écart inter-quartiles et l'étendue.
- La moyenne de prix par nuit est de 152.3\$. Comment interprétez-vous la différence entre la moyenne et la médiane ?
- Parmi les indicateurs numériques calculés avant, lesquels sont des indicateurs de dispersion et lesquels sont des indicateurs de positions ?
- Voici le Boxplot (boîte à moustache) pour la variable 'prix'.



- (a) Calculer les extrémités des moustaches.
- (b) Y a-t-il des valeurs aberrantes ? Justifier votre réponse.

B- Analyse Bivariée : Etude entre Prix et Neighbourhood (arrondissement)

La ville de New York compte 5 arrondissements (neighbourhood). On s'intéresse maintenant à étudier le lien entre les deux variables arrondissements et le prix des locations dans ces arrondissements. Le logiciel R nous fournit les résultats suivants :

```
> model <- lm (price~as.factor(neighbourhood),data=Airbnb)
> anova(model)
```

Analysis of Variance Table

```
Response: price
           Df  Sum Sq Mean Sq F value Pr(>F)
as.factor(neighbourhood) 68 1253070   18428  1.1695 0.1819
Residuals                 431 6791083   15757
```

1. Donner la variance inter groupes et la variance intra groupes. En déduire la variation totale.
2. Calculer le rapport de corrélation et interpréter cette valeur.

C- Analyse Bivariée : Etude entre Room-Type (type de chambre) et Neighbourhood (arrondissement)

On donne le tableau de contingence

	Entire home/apt	Private room	Shared room
Bronx	3	4	0
Brooklyn	139	98	0
Manhattan	139	86	4
Queens	10	12	0
Staten Island	0	5	0

1. Etablir le tableau complet des effectifs observés en ajoutant les effectifs marginaux.
2. Calculer et interpréter les valeurs suivantes $n_{\cdot 1}$, $f_{5\cdot}$, $f_{\cdot 2}$.
3. Donner le tableau de profils colonnes. Comparer le tableau de profils colonnes avec le profil moyen colonne. Que pouvez-vous prédire sur le lien entre ces deux variables ?

On donne le tableau des effectifs théoriques

	Entire home/apt	Private room	Shared room
Bronx	4.074	2.87	0.056
Brooklyn	137.934	97.17	?
Manhattan	133.278	93.89	1.832
Queens	12.804	9.02	0.176
Staten Island	2.910	?	0.04

4. Compléter les valeurs manquantes dans le tableau des effectifs théoriques, en détaillant les calculs.
5. Le calcul de la distance du khi-deux nous donne la valeur 15.139. Expliquer comment cette distance est calculée.
6. Y a-t-il un lien entre l'arrondissement et le type de chambre ? Justifiez votre réponse.

d.d.l.	4	5	6	7	8	9	10	15
Seuil	9.49	11.075	12.59	14.07	15.51	16.92	18.31	24.99

7. Faites vous confiance à ce résultat ? Justifiez votre réponse.

D- Classification des appartements en fonction de leur prix, latitude et longitude

On s'intéresse à une classification des appartements à partir de leur prix, latitude et longitude. Avec le logiciel R, on obtient les résultats suivants :

```
> kmean <- kmeans(Airbnbclus, centers=5)
print(kmean)
```

```
K-means clustering with 5 clusters of sizes 170, 15, 98, 121, 96
```

Cluster means:

	latitude	longitude	price
1	0.09793711	-0.5799051	0.1990332
2	-0.34840931	-0.5511168	3.7335244
3	1.61538948	0.6041057	-0.2437888
4	-0.57724555	0.8876835	-0.3805448
5	-1.04046485	-0.6225150	-0.2073050

Within cluster sum of squares by cluster:

```
[1] 121.4429   143.0395   89.2709   170.9241   95.5637
(between_SS / total_SS =  58.6 %)
```

Available components:

```
[1] "cluster"      "centers"       "totss"        "withinss"      "tot.withinss"
[6] "betweenss"    "size"          "iter"         "ifault"
```

1. Quelle méthode a été utilisée pour effectuer cette classification ?
2. Calculer l'inertie intra-classes.
3. Donner le pourcentage d'inertie expliqué par les classes.
4. Calculer l'inertie inter-classes.
5. Déduire l'inertie totale.
6. Proposer une autre méthode de classification et donner la différence entre les deux méthodes.

7. On donne les affectations des 30 premiers appartements ainsi que l'arrondissement de ces appartements :

```
kmean.cluster Airbnb.neighbourhood_group
1           5             Brooklyn
2           1             Manhattan
3           3             Manhattan
4           5             Brooklyn
5           3             Manhattan
6           1             Manhattan
7           4             Brooklyn
8           1             Manhattan
9           3             Manhattan
10          1             Manhattan
11          3             Manhattan
12          1             Manhattan
13          5             Brooklyn
14          3             Manhattan
15          1             Manhattan
16          4             Brooklyn
17          5             Brooklyn
18          5             Brooklyn
19          5             Brooklyn
20          3             Manhattan
21          5             Brooklyn
22          3             Manhattan
23          1             Manhattan
24          3             Manhattan
25          3             Manhattan
26          4             Brooklyn
27          1             Manhattan
28          4             Brooklyn
29          2             Manhattan
30          5             Brooklyn
```

Peut-on considérer que les clusters correspondent aux 5 arrondissements ? Justifier votre réponse.

Exercice 2

On considère data : *Climfrance.txt*. Ces données se composent de 36 lignes (observations) et 11 colonnes (caractéristiques/variables). Les caractéristiques sont : l'altitude, la latitude, la longitude, la température annuelle moyenne, la température annuelle maximale, la température annuelle minimale, l'humidité relative, les précipitations annuelles moyennes, les précipitations maximales en 24 heures, le nombre de jours de pluie et le nombre d'heures d'ensoleillement par an.

```
clim = read.table("Climfrance.txt", header = T, sep = ";", dec = ".")
install.packages("FactoMineR")
library(FactoMineR)
res.PCA.clim <- PCA(clim)
head(res.PCA.clim$eig)
##   eigenvalue   percentage of variance      cumulative percentage of variance
comp 1  4.6985564            42.714149                  42.71415
comp 2  2.9427020            26.751837                  69.46599
```

comp 3	1.3401647	12.183316	81.64930
comp 4	0.7815300	7.104818	88.75412
comp 5	0.5514082	5.012802	93.76692
comp 6	0.2385331	2.168483	95.93540

```
> res.PCA.clim$var$contrib[,1:4]
```


	Dim.1	Dim.2	Dim.3	Dim.4
altitude	2.84792993	27.380371	0.1788591	1.15421895
lat	9.97555726	10.421259	4.7106116	1.84063577
lon	6.02050855	2.025628	17.3696828	36.95051294
t_mean	10.14368290	15.869571	1.8020756	0.07607592
t_max	7.13248282	12.461242	0.1501642	14.19652610
t_min	9.22985599	11.526418	2.4517041	8.83405789
relhumidity	11.69989549	6.993222	3.0985483	3.20138110
p_mean	0.01680045	4.448227	56.7672194	9.42186140
p_max24h	12.57535176	3.476664	8.3729141	2.68703808
rainydays	16.59068209	1.338614	4.8983872	4.76582364
sun_shine_hperyr	13.76725277	4.058785	0.1998335	16.87186820


```
> res.PCA.clim$var$cos2[,1:4]
```

	Dim.1	Dim.2	Dim.3	Dim.4
altitude	0.1335494714	0.81604125	0.002265643	0.009432545
lat	0.4677890372	0.31059394	0.059670231	0.015042103
lon	0.2823228641	0.06037157	0.220025144	0.301968164
t_mean	0.4756730411	0.47297476	0.022827241	0.000621710
t_max	0.3344672570	0.37139335	0.001902159	0.116017305
t_min	0.4328204769	0.34353196	0.031056211	0.072193971
relhumidity	0.5486493340	0.20842513	0.039249913	0.026162429
p_mean	0.0007878324	0.13257442	0.719081386	0.076997637
p_max24h	0.5897025642	0.10361807	0.106061328	0.021959099
rainydays	0.7779955548	0.03989588	0.062048822	0.038947416
sun_shine_hperyr	0.6455950031	0.12096755	0.002531330	0.137880821

```
plot(res.PCA.clim, choix="var")
```

```
plot(res.PCA.clim, choix="ind")
```





En regardant le résultat de la fonction PCA, répondre aux questions suivantes :

1. Combien y-a-t-il d'axes au total ? Justifiez votre réponse.
2. Combien d'axes peut-on choisir pour interpréter le résultat ? Pourquoi ? A quoi correspond la somme des valeurs propres ?
3. Quelle est la contribution moyenne d'une variable à la construction d'un axe donné ? Quelles variables contribuent majoritairement à la construction du deuxième axe ?
4. Donner une interprétation possible des 2 premiers axes en partant des variables qui sont corrélées avec eux.
5. Donner, en justifiant, le nom d'une variable mal représentée sur le plan principal. Et indiquer sur quel axe cette variable est-elle bien représentée.
6. Interpréter les caractéristiques de ville "Brest" et "Lyon" et "Pic-du-Midi".