

Théorie des Langages

Yannick Le Nir Gaspard Férey

CY tech

ING1



La classification de Chomsky

Langages décidables et hiérarchie de classes

- Les langages de type 3 : rationnels ou réguliers
- Les langages de type 2 : algébriques ou hors contexte
- Les langages de type 1 : sensibles au contexte
- Les langages de type 0 : tous les autres décidables

Chaque ensemble est strictement inclus dans ceux de numéro inférieur.

Grammaire de type 3

Définition

Une grammaire $G = \langle T, N, S, P \rangle$ est de type 3 si les règles de production sont de la forme :

- soit $A \rightarrow a$ où $A \in N$ et $a \in T \cup \{\varepsilon\}$
- soit $A \rightarrow B a$ (ou $a B$) où $A, B \in N$ et $a \in T$

Langage associé

Un langage est de type 3 s'il peut être engendré par une grammaire de type 3.

Utilisation des grammaires de type 3

Domaines

- Occurrence de motifs dans une chaîne (Recherche d'informations)
- Expressions régulières (Shell, C, emacs)
- Séquence de l'ADN (Génôme)
- Apprentissage de grammaires pour l'IA

Exemple de grammaire

Affectation numérique

La grammaire $G = \langle T, N, S, P \rangle$ du cours précédent pour l'analyse lexicale de l'affectation numérique est de type 3 :

- $T = \text{lettre} \cup \text{chiffre} \cup \{+, -, *, /, =, .\}$
- $N = \{\text{mot}, \text{nombre}, \text{opérateur}, \text{nombre}, \text{identifiant}\}$
- $S = \text{mot}$
- $P = \left\{ \begin{array}{l} \text{mot} \rightarrow \text{opérateur}, \\ \text{opérateur} \rightarrow + \mid - \mid * \mid / \mid =, \\ \text{mot} \rightarrow \text{nombre}, \\ \text{nombre} \rightarrow (\text{chiffre}^+) \mid (\text{chiffre}^+).(\text{chiffre}^+), \\ \text{mot} \rightarrow \text{identifiant}, \\ \text{identifiant} \rightarrow \text{lettre} \mid \text{identifiant}(\text{lettre} \mid \text{chiffre}) \end{array} \right\}$

Grammaire de type 2

Définition

Une grammaire $G = \langle T, N, S, P \rangle$ est de type 2 si les règles de production sont de la forme :

- $A \rightarrow \alpha$ où $A \in N$ et $\alpha \in (N \cup T)^*$

Le membre gauche est donc **exactement un** non terminal alors que le membre droit est quelconque.

Langage associé

Un langage est de type 2 s'il peut être engendré par une grammaire de type 2.

Grammaires de type 2

Exemple de grammaire

Le fameux langage $a^n b^n$ peut être engendré par la grammaire hors contexte $G = \langle T, N, S, P \rangle$ avec :

- $T = \{a, b\}$
- $N = \{S\}$
- $S = S$
- $P = \{ S \rightarrow a S b \mid a b \}$

Domaines d'application

- Langages de programmation
- La plupart des constructions des langues naturelles

Autres grammaires

Grammaires de type 1

Une grammaire $G = \langle T, N, S, P \rangle$ est de type 1 si les règles de production sont de la forme :

$u A v \rightarrow u w v$ où $A \in N$, $u, v \in T^*$ et $w \in (N \cup T)^*$

Grammaires de type 0

Une grammaire $G = \langle T, N, S, P \rangle$ est de type 0 si les règles de production sont quelconques.

Théorèmes

- Une grammaire n'engendre qu'un seul langage. La réciproque est fausse.
- Les différentes familles de langages sont incluses les unes dans les autres : $L_3 \subset L_2 \subset L_1 \subset L_0$

Forme normale de Chomsky

Définition

Une grammaire de type 2 (sans ε) est dite sous **forme normale de Chomsky** si et seulement si toutes les règles sont de la forme :

- soit $A \rightarrow a$ (où $a \in T$)
- soit $A \rightarrow BC$ (où $B, C \in N$)

Théorème

Tout langage hors-contexte (de type 2) sans ε peut être engendré par une grammaire en forme normale de Chomsky.

Transformation en forme normale de Chomsky

Algorithme

- 1 remplacer tous les terminaux x en partie droite des règles par des non-terminaux X en ajoutant les règles $X \rightarrow x$
- 2 Toute règle $X \rightarrow YZW$ est remplacée par $X \rightarrow YV$ et $V \rightarrow ZW$
- 3 remplacer les règles $X \rightarrow Y$ par $X \rightarrow WZ$ si $Y \rightarrow WZ$

Exemple

Le langage $a^n b^n$ peut être engendré par la grammaire sous forme normale de Chomsky suivante : $\langle \{a, b\}, \{A, B, S\}, S, P \rangle$ avec

$$P = \left\{ \begin{array}{l} S \rightarrow A B, S \rightarrow A X, X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Algorithme CKY (Cocke, Kasami et Younger)

- Découvert indépendamment par Cocke, Kasami et Younger.
- Algorithme efficace pour reconnaître l'appartenance à un langage hors-contexte produit par une grammaire sous forme normale de Chomsky.

Algorithme CKY

Problème et algorithme

- Données :

- ▶ G une grammaire sous forme normale de Chomsky
- ▶ w : mot de longueur n

- Question : w appartient-il à $L(G)$?

- Idée :

- ▶ Pour chaque sous-mot m de w ($m = w[i,j]$), on peut construire successivement

$$M_{i,j} = \{X \in N \mid \text{tels que } X \rightarrow^* m\}$$

- ▶ Il suffit alors de vérifier si le symbole axiome S fait partie des non-terminaux obtenus pour le mot entier

Construction

- Tableau triangulaire : colonnes numérotées par $i = 1, 2, \dots, n$ (les positions de début de mot dans w) et lignes par $j = 1, 2, \dots, n$ (les longueurs possibles).
- Remplissage de la ligne 1 puis 2 ...
- La p -ième case de la ligne k correspond aux non-terminaux qui peuvent engendrer $w[p, k]$.
- On examine donc toutes les coupures du mot $w[p, k]$ en deux sous-mots : $w[p, l]$ et $w[p + l, k - l]$.
- Pour tous les Y possibles et tous les l compris entre 1 et k , on regarde toutes les expressions $X_p X_{p+l}$ en recherchant s'il existe Y dans la grammaire tel que $Y \rightarrow X_p X_{p+l}$.

Analyse CKY

Déroulement du CKY

4				
3				
2				
1				
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Analyse CKY

Déroulement du CKY

4				
3				
2				
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Analyse CKY

Déroulement du CKY

4				
3				
2	\emptyset			
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Analyse CKY

Déroulement du CKY

4				
3				
2	\emptyset	S		
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3				
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3				
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3	∅			
2	∅	S	∅	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3	\emptyset			
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Analyse CKY

Déroulement du CKY

4				
3	\emptyset	X		
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3	\emptyset	X		
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4				
3	\emptyset	X		
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4	\emptyset			
3	\emptyset	X		
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4	\emptyset			
3	\emptyset	X		
2	\emptyset	S	\emptyset	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Déroulement du CKY

4	S			
3	∅	X		
2	∅	S	∅	
1	A	A	B	B
input	a	a	b	b

$$P = \left\{ \begin{array}{l} S \rightarrow A B \\ S \rightarrow A X \\ X \rightarrow S B \\ A \rightarrow a \\ B \rightarrow b \end{array} \right\}$$

Analyse CKY

Algorithme

Données : $G = \langle T, N, P, S \rangle$ et w un mot de T^*

$n \leftarrow |w|$

$V \leftarrow \text{matrix}(n, n)$

// Sous-mots d'une lettre

pour $i = 1$ à n **faire**

$V[i, 1] = \{A \mid A \rightarrow a \in P \text{ et } w[i] = a\}$

// Sous-mots de plusieurs lettres

pour $j = 2$ à n **faire**

pour $i = 1$ à $n - j + 1$ **faire**

$V[i, j] \leftarrow \emptyset$

pour $k = 1$ à $j - 1$ **faire**

$V[i, j] = V[i, j] \cup$
 $\{A \mid A \rightarrow BC \in P, B \in V[i, k] \text{ et } C \in V[i + k, j - k]\}$

w reconnu par G ssi $S \in V[1, n]$.

Complexité

- n^2 coupures en deux un mot d'au plus n lettres
- n coupures à effectuer à chaque fois
- Complexité de l'algorithme de l'ordre de n^3 par rapport à la longueur n du mot d'entrée.
- Les langages hors-contexte peuvent être reconnus en un temps polynomial.

JFLAP

L'algorithme est illustré dans JFLAP 7.0 et (en plus détaillé) dans JFLAP 8.0 .