

TD5 - Grammaires de type 2 et algorithme CKY

Objectifs

- Notions de langage algébrique
- Transformer une grammaire sous forme normalisée de Chomsky
- Tester l'appartenance d'un mot à une grammaire sous forme normalisée de Chomsky
 - Algorithme CKY
- Application au traitement des langages naturels

Rappels et notations

Les termes *algébrique* et *hors-contexte* sont synonymes quand il s'agit de grammaire ou de langage. Une grammaire $G = \langle T, N, S, P \rangle$ est algébrique quand toutes les règles de P sont de la forme :

- $X \rightarrow a$ où $a \in T$ et $X \in N$
- $X \rightarrow Y$ où $Y \in (N \cup T)^*$ et $X \in N$

Une grammaire $G = \langle T, N, S, P \rangle$ hors-contexte **qui ne produit pas** ε est dite sous forme normale de Chomsky si et seulement si toutes les règles de P sont de la forme :

- $A \rightarrow a$ où $a \in T$
- $A \rightarrow BC$ où $B, C \in N$

Le mot vide, ε , peut également être noté λ (c'est notamment le cas en JFLAP).

Procédure de mise sous forme normalisée de Chomsky

1. Remplacer tous les terminaux x en partie droite des règles par des non terminaux en ajoutant des règles de la forme $X \rightarrow x$
2. Transformer les parties droites des règles comme suit.

$X \rightarrow YZW$ est remplacée par deux règles : $X \rightarrow YV$ et $V \rightarrow ZW$

3. Transformer les parties droites des règles comme suit :

$X \rightarrow Y$ remplacée par $X \rightarrow WZ$ pour chaque W et Z tels que $Y \rightarrow WZ$

Algorithme CKY

On utilisera l'algorithme de Coke, Younger et Kasami (CKY) pour tester si un mot w est reconnu par une grammaire sous forme normale de Chomsky.

Données : $G = \langle T, N, P, S \rangle$ et w un mot de T^*

$n \leftarrow |w|$

$v \leftarrow \text{matrix}(n, n)$

pour $i = 1$ à n faire

$v[i, 1] =$

$\{A \text{ tel que } A \text{ est le membre gauche d'une règle } A \rightarrow a \text{ et } a \text{ est le } i\text{-ème symbole du mot } w\}$

pour $j = 2$ à n faire

pour $i = 1$ à $n - j + 1$ faire

$v[i, j] \leftarrow \emptyset$

pour $k = 1$ à $j - 1$ faire

$v[i, j] = v[i, j] \cup$

$\{A \text{ tel que } A \text{ est le membre gauche d'une règle } A \rightarrow BC \text{ avec } B \in v[i, k] \text{ et } C \in v[i + k, j - k]\}$

Algorithme 1 : Algorithm CKY

Le mot w est reconnu par la grammaire ssi $S \in v[1, n]$.

Exercice 1. Reconnaissance d'un mot par l'algorithme CKY

Soit $G = \langle T, N, S, P \rangle$ une grammaire avec

$$T = \{a, b\}$$

$$N = \{S, A, B\}$$

$$S = S$$

$$P = \left\{ \begin{array}{l} S \rightarrow bA \mid aB \\ A \rightarrow a \mid aS \mid bAA \\ B \rightarrow b \mid bS \mid aBB \end{array} \right\}$$

Question 1. Est-ce que cette grammaire est algébrique ? rationnelle ?

Question 2. Mettre cette grammaire sous forme normalisée de Chomsky.

Question 3. En utilisant l'algorithme CKY, montrer que le mot $aabbab$ appartient au langage engendré par la grammaire.

Exercice 2. Des propositions très relatives

On s'intéresse aux constructions de phrases avec des propositions relatives.

Soit $G = \langle T, N, S, P \rangle$ une grammaire avec

$T = \{\text{que}, \text{qui}, \text{regarde}, \text{regardent}, \text{mange}, \text{mangent}, \text{dort}, \text{dorment}, \text{tombe}, \text{tombent}, \text{une}, \text{un}, \text{la}, \text{le}, \text{des}, \text{les}, \text{pommes}, \text{pomme}, \text{femme}, \text{femmes}, \text{Pierre}, \text{Marie}\}$

$N = \{\text{s}, \text{sn}, \text{reln}, \text{rela}, \text{sv}, \text{proa}, \text{pron}, \text{vt}, \text{vi}, \text{det}, \text{n}, \text{np}\}$

$S = \text{s}$

$$P = \left\{ \begin{array}{l} \text{s} \rightarrow \text{sn sv} \\ \text{sn} \rightarrow \text{det n reln} \mid \text{det n rela} \mid \text{np reln} \mid \text{np rela} \mid \text{det n} \mid \text{np} \\ \text{reln} \rightarrow \text{pron sv} \\ \text{rela} \rightarrow \text{proa sn vt} \\ \text{sv} \rightarrow \text{vi} \mid \text{vt sn} \\ \text{proa} \rightarrow \text{que} \\ \text{pron} \rightarrow \text{qui} \\ \text{vt} \rightarrow \text{regarde} \mid \text{regardent} \mid \text{mange} \mid \text{mangent} \\ \text{vi} \rightarrow \text{dort} \mid \text{dorment} \mid \text{tombe} \mid \text{tombent} \\ \text{det} \rightarrow \text{une} \mid \text{un} \mid \text{la} \mid \text{le} \mid \text{des} \mid \text{les} \\ \text{n} \rightarrow \text{pommes} \mid \text{pomme} \mid \text{femme} \mid \text{femmes} \\ \text{np} \rightarrow \text{Pierre} \mid \text{Marie} \end{array} \right\}$$

Légende :

- reln \iff proposition relative nominative
- rela \iff proposition relative accusative
- proa \iff pronom relatif accusatif
- pron \iff pronom relatif nominatif
- vi \iff verbe intransitif
- vt \iff verbe transitif
- det \iff déterminant
- n \iff nom commun
- np \iff nom propre

Question 1. Est-ce que cette grammaire est algébrique ? rationnelle ?

Question 2. Vérifier l'appartenance de la phrase **une pomme que Pierre regarde tombe** au langage reconnu par la grammaire en utilisant un arbre syntaxique.

Question 3. Appliquer l'algorithme CKY pour vérifier :

- l'appartenance de la phrase **une pomme que Pierre regarde tombe** au langage engendré par la grammaire
- le rejet de la phrase **une pomme qui Pierre regarde tombe** du langage engendré par la grammaire

Exercice 3. JFLAP

L'analyse CKY peut être effectuée par le logiciel JFLAP (<http://jflap.org/jflaptmp>).

Pour cela, on se place en mode **grammaire** (*Grammar*). Ensuite, on rentre les différentes règles de la grammaire non normalisée.

On peut alors vérifier qu'il s'agit bien d'une grammaire algébrique (*context-free*) grâce à l'item *Test for Grammar Type* de l'onglet *Test*.

On peut ensuite normaliser la grammaire grâce à l'item (*Transform Grammar*) de l'onglet *Convert*.

On peut ensuite réaliser l'analyse CKY grâce à la commande *CYK Parse* de l'onglet *Input*.