TP2 : Analyse bivariée : Croisement Quantitatif-Quantitatif

Durée : 3h

L'objectif de ce TP est d'étudier un lien éventuel entre deux variables quantitatives et de construire un modèle décrivant ce lien le cas échéant.

Exercice 1 — Un peu de géométrie

Dans une population Ω de taille n, on observe deux variables quantitatives continues, $x=\{x_k\}_{k=1,\dots,n}$ et $y=\{y_k\}_{k=1,\dots,n}$, de moyennes $\bar{x}$ et $\bar{y}$ et de variances s_x^2 et s_y^2.

On définit le produit scalaire,

$$<x,y>=\frac{1}{n}\sum_{k=1}^{n} x_k y_k \,.$$

1) Montrez que la covariance est le produit scalaire entre les vecteurs centrés $x-\bar{x}$ et $y-\bar{y}$. Puis exprimez le produit scalaire en fonction de C_{xy} et les moyennes.
2) Déterminez la norme du vecteur centré $x-\bar{x}$ puis la norme de x en fonction de sa variance et sa moyenne.
3) Comment peut-on écrire la moyenne $\bar{x}$ à l'aide du produit scalaire ?
4) D'un point de vue géométrique à quoi correspond le coefficient de corrélation linéaire ?
5) On dit que les deux variables x et y sont non corrélées si $r_{xy}=0$ et entièrement corrélées si $r_{xy}=\pm 1$. Qu'est-ce que cela signifie géométriquement ?
6) A l'aide du produit scalaire, montrez que :

   a) la moyenne des valeurs prédites est égale à la moyenne de la série observée y.

   b) les résidus sont de moyenne nulle.

Exercice 2 — Chômage en 1982

On donne pour les six premiers mois de l'année 1982 les nombres d'offres d'emploi (concernant des emplois durables à temps plein) et de demandes d'emploi (déposées par des personnes sans emploi, immédiatement disponibles, à la recherche d'un emploi durable à plein temps). Les nombres sont exprimés en milliers.

Offres (x_i)	61	66,7	75,8	78,6	82,8	87,2
Demandes (y_i)	2034	2003,8	1964,5	1928,2	1885,3	1867,1

On a les résultats suivants

$$\bar{x} = 75{,}35 \qquad \bar{y} = 1947{,}15 \qquad s_x^2 = 97{,}49 \qquad s_y^2 = 4329{,}14 \qquad c_{xy} = -639{,}90$$

1) Calculer le coefficient de corrélation linéaire. Conclusion
2) Déterminer la droite de régression.
3) Calculer la prévision de la demande d'emploi s'il y a 61 milliers d'offres. Comparer avec la demande réelle.
4) Vérifier la formule de la décomposition de la variance. En déduire le coefficient de détermination.

Exercice 3 — Données : DepensesEduData.xls

Le fichier DepensesEduData.csv recense les dépenses publiques de certains états pour l'éducation ainsi que le nombre d'élèves (donnée Eurostat 2008).

```
tab <- read.table("DepensesEduData.csv",header=T,sep=";",dec=",")
summary(tab)
boxplot(tab$nbEleves,tab$Depenses)
```

1) Tracer le nuage de points des dépenses en fonction du nombre d'élèves.

```
### nuage de points
plot(tab$nbEleves,tab$Depenses,main="Budget en fonction du nombre
d'élèves en Europe", xlab="nombre d'étudiants (en
milliers)",ylab="Budget (K€)")
text(tab$nbEleves,tab$Depenses,row.names(tab),cex=0.8)
# cex=taille de la police
```

2) Calculer le coefficient de corrélation linéaire. Conclusion

```
cor(tab)          # calcule la corrélation entre les variables
```

3) Déterminer la droite de régression. Tracer la droite sur le graphique.

```
#  construit le modèle de régression linéaire / lm  = linear model
modele <- lm(Depenses ~ nbEleves, data=tab)
summary(modele)     # résume toutes les caractéristiques du modèle
attributes(modele) # donne tous les attributs de l'objet « lm »

modele$coef         # donne les coefficients de la droite

# trace la droite sur le nuage de points
abline(modele$coef[1],modele$coef[2],col="red",lwd=2)
```

4) Vérifier les hypothèses sur les résidus. Quel pays semble atypique par rapport au modèle ?

```
modele$fitted        # affiche les prévisions données par le modèle
                     # aux points du tableau
modele$residuals     # affiche les résidus

restd <- rstandard(modele)     # affiche les résidus standardisés

X11()     # ouvre une nouvelle fenêtre graphique
plot(modele$fitted, restd ,ylim=range(-2,2,restd),
                                        main="Résidus standardisés")
# range donne le min et le max d'une série de nombres

abline(h=2,col="red",lwd=2)     # ajoute les lignes pour détecter les
                                # observations atypiques
abline(h=-2,col="red",lwd=2)
text(modele$fitted, restd ,row.names(tab))  # ajoute le nom des pays
```

5) Supprimer le pays atypique et refaire la même chose.

6) Quel pourcentage de variabilité des dépenses est expliqué par la droite de régression ? Est-ce que vous validez le modèle ?

7) Calculer les budgets prédits par le modèle pour 1000, 6000 et 9500 milliers d'étudiants. Placer les sur le graphique.

```
newx <- data.frame(c(1000,6500,9000)) # nouveaux points
names(newx)= "nbEleves"
prev <- predict(modele,newdata=newx)  # calcul les prévisions aux
                                      # nouveaux points
plot(tab$nbEleves,tab$Depenses,main="Budget en fonction du nombre
                + d'élèves en Europe", xlab="nombre d'étudiants (en
                + milliers)",ylab="Budget (K€)")
points(t(newx),prev,col="green",lwd=2) # t pour transposer le
                                       # vecteur newx
```

Exercice 4 Ventes

(PY Bernard, exercices corrigés de statistique descriptive, ed. economica)

Une étude a été menée auprès d'entreprises afin d'établir le lien entre les quantités commandés d'un bien, Y, et son prix, X et on obtient les observations suivantes (Commandes.csv).

Prix de vente (€)	Quantités commandées
95	104
130	58
148	42
210	12
250	8
330	5

1) Tracer le nuage de points.
2) Calculer le coefficient de corrélation linéaire entre X et Y. Conclusion
3) Déterminer la droite de régression de Y en fonction de X.
4) Quel est le pourcentage de variation des quantités de commande expliquée par la droite de régression ?
5) Calculer les résidus et vérifier les hypothèses sur les résidus. Conclusion.
6) On pose u=log(x) et v=log(y). Quelle est la relation entre u et v ?
7) Calculer le coefficient de corrélation linéaire entre u et v.
8) Trouver la droite de régression de v sur u.
9) Quel est le pourcentage de variation des quantités de commande expliquée par la droite de régression ?
10) Valider le modèle.
11) En déduire la quantité qui serait commandée si le prix était fixé à 75€.

Exercice 1 (suite facultative)

7) Montrer que les résidus sont non corrélés avec la série X. Qu'est-ce que cela signifie ?
8) Montrer la formule de décomposition de la variance

$$s_y^2 = s_E^2 + s_R^2$$

où s_E^2 est la *variance expliquée* par la droite de régression, et s_R^2 est la *variance résiduelle.*

On peut alors montrer que le *coefficient de détermination*

$$R^2 = \frac{s_E^2}{s_y^2},$$

qui donne le taux de variance expliquée par la droite de régression, est égale au coefficient de corrélation linaire au carré, $R^2 = r_{xy}^2$.