

TP: Clustering

Exercise I:

$$x_1 = 1; x_2 = 2; x_3 = 9; x_4 = 12; x_5 = 20$$

1) a- $K=2$ $g_1=1$ et $g_2=20$ (K-means)

		x_1	x_2	x_3	x_4	x_5
		1	2	9	12	20
$g_1 = 1$	$(x_1=1)$	0	1	8	11	19
	$(x_5=20)$	19	18	11	8	0
$g_2 = 20$						

$$C_1 = \{x_1, x_2, x_3\} \rightarrow g_1 = \frac{x_1 + x_2 + x_3}{3} = \frac{1+2+9}{3} = 4$$

$$C_2 = \{x_4, x_5\} \rightarrow g_2 = 16$$

2ème Itération:

		x_1	x_2	x_3	x_4	x_5
		1	2	9	12	20
$g_1 = 4$		3	2	5	8	16
		15	14	7	4	4
$g_2 = 16$						

$$C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

les classes n'ont pas changé, alors on arrête l'algorithme.

①

$$\text{Centre de gravité } g = \frac{1+2+9+12+20}{5} = 8,8$$

• Inertie totale : $\frac{1}{15} \sum_{i=1}^5 d^2(x_i, g)$

$$= \frac{1}{5} \left[\underbrace{(1-8,8)^2}_{x_1 \downarrow g} + \underbrace{(2-8,8)^2}_{x_2 \downarrow g} + \underbrace{(9-8,8)^2}_{x_3 \downarrow g} + (12-8,8)^2 + (20-8,8)^2 \right]$$

$$= 48,56$$

• Inertie inter classe : $\frac{1}{5} \sum_{k=1}^2 n_k \cdot d^2(g_k, g)$

$$= \frac{1}{5} \left[\underbrace{(3) \cdot (4-8,8)^2}_{\text{eff de la classe } 1} + \underbrace{(2) \cdot (16-8,8)^2}_{\text{eff de la classe } 2} \right] = 34,56$$

• Inertie intra-classe = Inertie totale - Inertie inter-classe

$$= 48,56 - 34,56 = 14.$$

• pourcentage d'inertie expliquée par les classes:

$$R^2 = \frac{\text{Inertie inter-classe}}{\text{I total}} = \frac{34,56}{48,56} = 0,71$$

(2)

b) 1^{re} Iteration:

	x_1	x_2	x_3	x_4	x_5
$g_1 = 2$	1	2	9	12	20
	PL 0	7	10	18	

	x_1	x_2	x_3	x_4	x_5
$g_2 = 9$	8	7	0	3	11

$$C_1 = \{x_1, x_2\}$$

$$\rightarrow g_1 = \frac{1+2}{2} = 1,5$$

$$C_2 = \{x_3, x_4, x_5\} \rightarrow g_2 = \frac{9+12+20}{3} = 13,66$$

2^{eme} Iteration:

	x_1	x_2	x_3	x_4	x_5
$g_1 = 1,5$	1	2	9	12	20
	0,5	0,5	7,5	10,5	18,5

	x_1	x_2	x_3	x_4	x_5
$g_2 = 13,66$	12,66	11,66	4,66	1,66	6,34

$$C_1 = \{x_1, x_2\}$$

; Les classes n'ont pas changé, alors on arrête l'algorithme.

$$C_2 = \{x_3, x_4, x_5\}$$

Centre de gravité: $g = 8,8$

$$I_{\text{inter}} = \frac{1}{5} [2 \times (1,5 - 8,8)^2 + 3 \times (13,66 - 8,8)^2] = 35,48$$

$$I_{\text{total}} = 48,56$$

③

$$R^2 = \frac{35,48}{48,56} = 0,73$$

c) $K=3$; $g_1=1$; $g_2=9$; $g_3=12$

1^{er} itération:

	x_1	x_2	x_3	x_4	x_5
$g_1=1$	1	2	9	12	20
$g_2=9$	0	1	8	11	19
$g_3=12$	8	7	0	3	11
	11	10	3	0	8

$$C_1 = \{x_1, x_2\} \rightarrow g_1 = \frac{1+2}{2} = 1.5$$

$$C_2 = \{x_3\} \rightarrow g_2 = 9$$

$$C_3 = \{x_4, x_5\} \rightarrow g_3 = \frac{12+20}{2} = 16$$

2^{de} itération:

	x_1	x_2	x_3	x_4	x_5
$g_1=1.5$	1	2	9	12	20
$g_2=9$	0.5	0.5	7.5	10.5	18.5
$g_3=16$	8	7	0	3	11
	15	14	7	4	4

④

$$C_1 = \{X_1, X_2\} \rightarrow g_1 = 1,5$$

$$C_2 = \{X_3, X_4\} \rightarrow g_2 = 10,5$$

$$C_3 = \{X_5\} \rightarrow g_3 = 20$$

3ème Itération:

	X_1	X_2	X_3	X_4	X_5
x_1	1	2	9	12	80
$g_1 = 1,5$	0,5	0,5	7,5	10,5	18,5
$g_2 = 10,5$	8,5	8,5	1,5	1,5	9,5
$g_3 = 20$	19	18	11	8	0

$$C_1 = \{X_1, X_2\}$$

$$C_2 = \{X_3, X_4\}$$

$$C_3 = \{X_5\}$$

; les classes t'pas change, donc
on arrête l'algorithme.

$$\bullet I_{\text{inter}} = 1/5 [2 \times (1,5 - 8,8)^2 + 2(10,5 - 8,8)^2 + 1 \cdot (20 - 8,8)^2] \\ = 47,56.$$

$$R^2 = \frac{I_{\text{inter}}}{I_{\text{total}}} = \frac{47,56}{48,56} = 0,98$$

(5)

d) On peut utiliser l'errance inter-classes pour déterminer le meilleur parmi deux partitions qui ont un nombre de classes. plus ce errance est grande plus le pourcentage d'errance expliquée par la partition obtenue est grande. Ici, la meilleure partition entre "a" et "b" est celle de la deuxième partie. (R^2 plus élevée que 1^o)

⚠ Le partition du "c" a le R^2 le plus élevé, mais c'est mieux d'avoir un petit nb de classes.

2) Méthode CAH. en utilisant distance minimale :

1^{er} itération : On considère chaque point x_i comme un classe et on calcule distance entre chaque deux points (classes).

	$C_1 = \{x_1\}$	$C_2 = \{x_2\}$	$C_3 = \{x_3\}$	$C_4 = \{x_4\}$	$C_5 = \{x_5\}$
$C_1 = \{x_1\}$	0	1	8	11	19
$C_2 = \{x_2\}$	1	0	7	10	18
$C_3 = \{x_3\}$	8	7	0	3	11
$C_4 = \{x_4\}$	11	10	3	0	8
$C_5 = \{x_5\}$	19	18	11	8	0

Les classes les plus proches sont (C_1) et (C_2) , dont les regroupements.

$$C_1 = \{x_1, x_2\}$$

$$C_2 = \{x_3\}$$

$$C_3 = \{x_4\}$$

$$C_4 = \{x_5\}$$

⑥

2ème itération: On regroupe les classes les plus proches.

	C_1 $\{1, 2\}$	C_2 $\{9\}$	C_3 $\{1, 2\}$	C_4 $\{20\}$
C_1 $\{1, 2\}$	0	7	10	18
C_2 $\{9\}$	7	0	3	11
C_3 $\{1, 2\}$	10	3	0	8
C_4 $\{20\}$	18	11	8	0

(*) on prend $(9-2)=7$
et pas $(9-1)=8$
car on veut la
distance minimale

Les classes les plus proches sont : C_2 et C_3 ; ont été groupées

donc

$$C_1 = \{x_1, x_2\}$$

$$C_2 = \{x_4, x_3\}$$

$$C_3 = \{x_5\}$$

On regroupe tous avec x_1

3ème itération

	C_1 $\{1, 2\}$	C_2 $\{9, 12\}^*$	C_3 $\{20\}$
C_1 $\{1, 2\}$	0	7	18
C_2 $\{9, 12\}$	7	0	8
C_3 $\{20\}$	18	8	0

pour calculer
distances entre
 $\{9, 12\}$ et $\{1, 2\}$

on prend la
combinaison qui
va nous donner le
plus petit distance.
expt: $9-2=7$

les classes les plus proches sont: C_2 avec C_1
ont été regroupées ; $C_1 = \{x_1, x_2, x_3, x_4\}$
 $C_2 = \{x_5\}$ ⑦

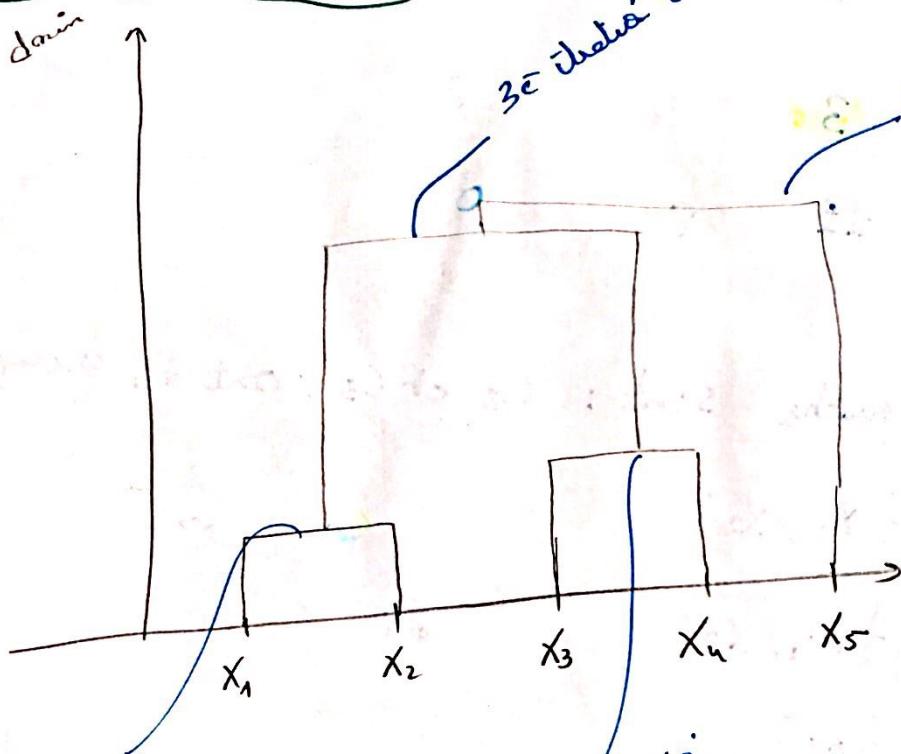
4ème Itération:

C_1	$\{1, 2, 9, 12\}$	C_2	$\{20\}$
	$\{1, 2, 9, 12\}$		$\{20\}$
$C_2 \{20\}$		0	8

On groupe à la fin tous les classes ensemble.

$x_1, x_2, x_3 \dots x_n$

Dendrogramme:



1ère itération on a regroupé x_1 avec x_2

2ème itération on a regroupé le x_3 avec x_4

3ème itération on a regroupé les x_1, x_2, x_3 et x_4

4ème itération d'la fin il faut avoir seul groupe