

## TD5 - Grammaires de type 2 et algorithme CKY

### Objectifs

- Notions de langage algébrique
- Transformer une grammaire sous forme normalisée de Chomsky
- Tester l'appartenance d'un mot à une grammaire sous forme normalisée de Chomsky
  - Algorithme CKY
- Application au traitement des langages naturels

### Rappels et notations

Les termes *algébrique* et *hors-contexte* sont synonymes quand il s'agit de grammaire ou de langage. Une grammaire  $G = \langle T, N, S, P \rangle$  est algébrique quand toutes les règles de  $P$  sont de la forme :

- $X \rightarrow a$  où  $a \in T$  et  $X \in N$
- $X \rightarrow Y$  où  $Y \in (N \cup T)^*$  et  $X \in N$

Une grammaire  $G = \langle T, N, S, P \rangle$  hors-contexte **qui ne produit pas**  $\varepsilon$  est dite sous forme normale de Chomsky si et seulement si toutes les règles de  $P$  sont de la forme :

- $A \rightarrow a$  où  $a \in T$
- $A \rightarrow BC$  où  $B, C \in N$

**Le mot vide,  $\varepsilon$ , peut également être noté  $\lambda$  (c'est notamment le cas en JFLAP).**

#### Procédure de mise sous forme normalisée de Chomsky

1. Remplacer tous les terminaux  $x$  en partie droite des règles par des non terminaux en ajoutant des règles de la forme  $X \rightarrow x$
2. Transformer les parties droites des règles comme suit.

$X \rightarrow YZW$  est remplacée par deux règles :  $X \rightarrow YV$  et  $V \rightarrow ZW$

3. Transformer les parties droites des règles comme suit :

$X \rightarrow Y$  remplacée par  $X \rightarrow WZ$  pour chaque  $W$  et  $Z$  tels que  $Y \rightarrow WZ$

### Algorithme CKY

On utilisera l'algorithme de Cocke, Younger et Kasami (CKY) pour tester si un mot  $w$  est reconnu par une grammaire sous forme normale de Chomsky.

**Données :**  $G = \langle T, N, P, S \rangle$  et  $w$  un mot de  $T^*$

$n \leftarrow |w|$

$v \leftarrow \text{matrix}(n, n)$

**pour**  $i = 1$  **à**  $n$  **faire**

$v[i, 1] =$   
     $\{A \text{ tel que } A \text{ est le membre gauche d'une règle } A \rightarrow a \text{ et } a \text{ est le } i\text{-ème symbole du mot } w \}$

**pour**  $j = 2$  **à**  $n$  **faire**

**pour**  $i = 1$  **à**  $n - j + 1$  **faire**

$v[i, j] \leftarrow \emptyset$

**pour**  $k = 1$  **à**  $j - 1$  **faire**

$v[i, j] = v[i, j] \cup$

$\{A \text{ tel que } A \text{ est le membre gauche d'une règle } A \rightarrow BC \text{ avec } B \in v[i, k] \text{ et } C \in v[i + k, j - k]\}$

### Algorithme 1 : Algorithm CKY

Le mot  $w$  est reconnu par la grammaire ssi  $S \in v[1, n]$ .

### Exercice 1. Reconnaissance d'un mot par l'algorithme CKY

Soit  $G = \langle T, N, S, P \rangle$  une grammaire avec

$$T = \{a, b\}$$

$$N = \{S, A, B\}$$

$$S = S$$

$$P = \left\{ \begin{array}{l} S \rightarrow bA \mid aB \\ A \rightarrow a \mid aS \mid bAA \\ B \rightarrow b \mid bS \mid aBB \end{array} \right\}$$

**Question 1.** Est-ce que cette grammaire est algébrique? rationnelle?

**Question 2.** Mettre cette grammaire sous forme normalisée de Chomsky.

**Question 3.** En utilisant l'algorithme CKY, montrer que le mot  $aabbab$  appartient au langage engendré par la grammaire.

### Exercice 2. Des propositions très relatives

On s'intéresse aux constructions de phrases avec des propositions relatives.

Soit  $G = \langle T, N, S, P \rangle$  une grammaire avec

$T = \{\text{que, qui, regarde, regardent, mange, mangent, dort, dorment, tombe, tombent, une, un, la, le, des, les, pommes, pomme, femme, femmes, Pierre, Marie}\}$

$N = \{s, sn, reln, rela, sv, proa, pron, vt, vi, det, n, np\}$

$S = s$

$$P = \left\{ \begin{array}{l} s \rightarrow sn \ sv \\ sn \rightarrow det \ n \ reln \mid det \ n \ rela \mid np \ reln \mid np \ rela \mid det \ n \mid np \\ reln \rightarrow pron \ sv \\ rela \rightarrow proa \ sn \ vt \\ sv \rightarrow vi \mid vt \ sn \\ proa \rightarrow \text{que} \\ pron \rightarrow \text{qui} \\ vt \rightarrow \text{regarde} \mid \text{regardent} \mid \text{mange} \mid \text{mangent} \\ vi \rightarrow \text{dort} \mid \text{dorment} \mid \text{tombe} \mid \text{tombent} \\ det \rightarrow \text{une} \mid \text{un} \mid \text{la} \mid \text{le} \mid \text{des} \mid \text{les} \\ n \rightarrow \text{pommes} \mid \text{pomme} \mid \text{femme} \mid \text{femmes} \\ np \rightarrow \text{Pierre} \mid \text{Marie} \end{array} \right.$$

Légende :

- $reln \iff$  proposition relative nominative
- $rela \iff$  proposition relative accusative
- $proa \iff$  pronom relatif accusatif
- $pron \iff$  pronom relatif nominatif
- $vi \iff$  verbe intransitif
- $vt \iff$  verbe transitif
- $det \iff$  déterminant
- $n \iff$  nom commun
- $np \iff$  nom propre

**Question 1.** Est-ce que cette grammaire est algébrique? rationnelle?

**Question 2.** Vérifier l'appartenance de la phrase **une pomme que Pierre regarde tombe** au langage reconnu par la grammaire en utilisant un arbre syntaxique.

**Question 3.** Appliquer l'algorithme CKY pour vérifier :

- l'appartenance de la phrase **une pomme que Pierre regarde tombe** au langage engendré par la grammaire
- le rejet de la phrase **une pomme qui Pierre regarde tombe** du langage engendré par la grammaire

### Exercice 3. JFLAP

L'analyse CKY peut être effectuée par le logiciel JFLAP (<http://jflap.org/jflaptmp>).

Pour cela, on se place en mode **grammaire** (*Grammar*). Ensuite, on rentre les différentes règles de la grammaire non normalisée.

On peut alors vérifier qu'il s'agit bien d'une grammaire algébrique (*context-free*) grâce à l'item *Test for Grammar Type* de l'onglet *Test*.

On peut ensuite normaliser la grammaire grâce à l'item (*Transform Grammar*) de l'onglet *Convert*.

On peut ensuite réaliser l'analyse CKY grâce à la commande *CYK Parse* de l'onglet *Input*.