

Statistiques Bivariables

Croisement Quanti - Quanti

Statistiques Bivariables = étude de deux caractères (variables) simultanément chez les individus.

But: Étudier s'il y a un lien entre ces deux variables.

Exp: On prend deux variables:

X = taux d'alcoolisme

Y = taux de suicides

et on étudie s'il y a un lien entre ces 2 variables.

Type de croisement: ces deux variables peuvent être:

① quantitatif \times quantitatif

② qualitatif \times quantitatif

③ qualitatif \times qualitatif

Pour chaque type de croisement, on a une étude différente. On commence par le Quanti \times Quanti.

1. Nuage des points:

• X et Y deux variables quantitatives sur un échantillon de taille (n) ; les objectifs:

① Déterminer s'il y a un lien (ou une corrélation) entre les deux variables.

② Construire un modèle qui permet d'expliquer Y par X (ou l'inverse) s'il y a un lien.

2. Droite de Régression:

* Soit $\{x_i\}_{i=1, \dots, n}$ les observations de X
et $\{y_i\}_{i=1, \dots, n}$ les observations de Y .

Objectif: trouver une fonction f tel que:
 $y_i = f(x_i) + \varepsilon_i$ / $\varepsilon = \text{erreur}$.

On se restreint aux fcts affines: $f(x) = ax + b$

- On cherche les coefficients \underline{a} et \underline{b} qui minimisent l'erreur quadratique moyenne.

$$EQ(a, b) = \frac{1}{n} \sum_i \varepsilon_i^2$$

$$= \frac{1}{n} \sum_i (y_i - (ax_i + b))^2$$

★ Droite de Régression de Y en X est:

$$y = \hat{a}x + \hat{b}$$

tel que: $\hat{a} = \frac{C_{xy}}{S_x^2}$ $\hat{b} = \bar{y} - \hat{a}\bar{x}$

$$C_{xy} = \frac{1}{n} \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

c'est la covariance entre X et Y.

S_x^2 = variance de X.

Ce droite traduit les variations de Y qui peuvent être expliquées par X.

★ Droite de Régression de X en Y.

$$x = \hat{a}y + \hat{b}$$

tel que: $\hat{a} = \frac{C_{xy}}{S_y^2}$ $\hat{b} = \bar{x} - \hat{a}\bar{y}$

Exp: lien taille ^X et poids ^Y chez les enfants de 6 ans.

• Equation de Y en X:

$$y = \hat{a}x + \hat{b}$$

$$\hat{a} = \frac{C_{xy}}{S_x^2} = \frac{16,27}{38,62} = 0,42$$

$$\hat{b} = \bar{y} - \hat{a}\bar{x} = (20,30) - (0,42)(113,20) = -27,38$$

donc

$$y = 0,42x - 27,38$$

Exp: Si taille d'un enfant est $x = 115$, estimer le poids ?

$$y = 0,42x - 27,38 = 0,42(115) - 27,38$$

(3)

$$= 20,92 \text{ Kg.}$$

Equation de la droite X en Y:

$$x = \hat{a}y + \hat{b}$$

$$\hat{a} = \frac{C_{xy}}{S_y^2} = \frac{16,27}{8,46} = 1,92$$

$$\hat{b} = \bar{x} - \hat{a}\bar{y} = 113,2 - (1,92)(20,30) = +74,15$$

donc

$$x = 1,92y + 74,15$$

Exp: Si le poids d'un enfant est 23 Kg, estimer son taille:

$$x = 1,92y + 74,15$$

$$= 1,92(23) + 74,15 = 118,31 \text{ cm}$$

Covariance: C'est un indicateur numérique du lien entre X et Y: plus il est loin de 0, plus les variables sont liées. [$C_{xy} = 0$, pas de lien entre les 2 variables alors elles sont indépendantes].

⚠ La covariance n'est pas normée, donc il prendra n'importe quelle valeur sur \mathbb{R} . pour cela pour étudier le lien entre X et Y, on définit le Coefficient de Corrélation.

• Coefficient de Corrélation (Coefficient de Pearson) :
pour étudier le lien entre deux variables quantitatives
X et Y : prend ces valeurs entre $[-1, 1]$

$$r_{xy} = \frac{C_{xy}}{s_x \cdot s_y}$$

on a aussi:

$$\hat{a} = \frac{C_{xy}}{S_x^2} \Rightarrow \hat{a} = \frac{r_{xy} \cdot s_y}{s_x}$$

Interprétation: ① $|r|$ proche de 1, alors X et Y sont
très liés entre eux par une droite affine

② $r < 0$: X et Y varie en sens inverse
Exp: $\begin{cases} X = \text{dépense} \\ Y = \text{Épargne} \end{cases}$
Si X augmente
donc Y diminue.

③ $r > 0$: X et Y varie de m^êm sens.

Exp: $\begin{cases} X = \text{taux nicotine dans sang} \\ Y = \text{risque avoir maladie pulmon} \end{cases}$
Si X augmente alors Y aussi

④ $|r| = 0$: On ne peut rien dire sur un
lien éventuel entre X et Y.

Exemple: pour poids et âge chez les enfants de 6 ans:

$$r_{xy} = \frac{C_{xy}}{s_x \cdot s_y} = \frac{16,27}{\sqrt{38,62} \times \sqrt{8,46}} \approx 0,9$$

• $r_{xy} \approx 1 \rightarrow$ l'éq de droite est pleinement justifiée.
• $r_{xy} > 0 \rightarrow$ plus la variable taille est grande
plus le poids est important et vice versa.

⑤

• Prévisions: on appelle (prévisions), les valeurs données par la droite de régression.

Pour chaque x_i on peut calculer \hat{y}_i :

\hat{y}_i = c'est la valeur approchée (estimée) de la vraie valeur y_i .

$$\overline{\hat{y}} = \bar{y}$$

mais

pas m^{ême} variance.

$$S_{\hat{y}}^2 = r_{xy}^2 \cdot S_y^2$$

Les \hat{y}_i estimés ont m^{ême} moyenne que la vraie valeur y_i .

• Résidus:

c'est l'écart entre y_i et \hat{y}_i :

$$e_i = y_i - \hat{y}_i$$

tel que: $\hat{y}_i = \hat{a}x_i + \hat{b}$

Erreur globale: $EQ(\hat{a}, \hat{b}) = \frac{1}{n} \sum_i e_i^2 = S_y^2 (1 - r_{xy}^2)$



Variance $Y \neq \text{variance } \hat{Y}$.

$$S_y^2 = S_{\hat{y}}^2 + S_e^2$$

variance
totale

variance
expliquée

variance des
résidus

Coefficient de détermination:

$$R^2 = \frac{S_{\hat{y}}^2}{S_y^2} = r^2_{xy}$$

(entre 0 et 1).

Donne proportion des observations expliquée par
la droite de régression (plus il est élevée plus c mieux)

Exp: On donne:

$$\begin{cases} S_{\hat{y}}^2 = 6,17 \\ S_e^2 = 1,44 \\ S_y^2 = 7,61 \end{cases}$$

$$\text{donc } R^2 = \frac{6,17}{7,61} = 0,81$$

\Rightarrow 81% de la variation des
poids observés est expliquée
par la droite de régression.

$$\underbrace{S_y^2}_{\text{variance totale}} = \underbrace{S_{\hat{y}}^2}_{\text{variance expliquée}} + \underbrace{S_e^2}_{\text{variance résiduelle}}$$

$$\bullet S_{\hat{y}}^2 = r^2_{xy} \cdot S_y^2$$

$$\bullet S_e^2 = S_y^2 (1 - r^2_{xy})$$

$$\bullet S_y^2 = \frac{1}{n} \sum_{k=1}^n (y_k - \bar{y})^2$$

r_{xy} = coeff de corrélat.

$$r_{xy} = \frac{C_{xy}}{s_x \cdot s_y}$$

⚠ Outliers (valeurs aberrantes)

Comment faire ??



+ Si on a une (plusieurs) valeur aberrantes :

- ① On retire la i^{ème} observation
- ② On refait un nouveau modèle sans la i^{ème}
- ③ On calcule $\hat{y}_{(-i)}$ (la prévision) avec le nouveau modèle.
pour Modèle sans (i)

- ④ On calcule le résidu :

$$e_{(-i)} = y_i - \hat{y}_{(-i)}$$

pour le
modèle sans
(i).

⚠ un résidu a valeur importante signale
une observation ab influente.

On :

$$e_{ii} = \frac{e_i}{1 - h_{ii}}$$

ou

$$h_{ii} = \frac{1}{n} + \frac{1}{n-1} \frac{(x_i - \bar{x})^2}{S_x^2}$$

calculé avec
modèle sans (i)

calculé avec
modèle initial
avec i^{ème} obs.

h_{ii} = Levier, prend ses
valeurs entre : $\frac{1}{n} \leq h_{ii} \leq 1$
Si h_{ii} proche de 1 alors on a
une observat influente

(9)

- Les résidus standardisés doivent être toujours entre $[-2, 2]$ [I.D.C à voir en ING2].
[Cq c'est l'hypothèse de normalité des résidus]

Résidu standardisé

$$S_i = \frac{e_i}{\hat{\sigma} \cdot \sqrt{1-h_{ii}}}$$