

	<p style="text-align: center;"><b>ING1-GM</b> EXAMEN DE DATA EXPLORATION 2021-2022</p>
2h	Examen papier 2 feuilles R/V manuscrites autorisées Calculatrice autorisée

## Exercice 1

On a interrogé une partie des élèves d'un collège pour connaître la distance qu'ils doivent parcourir pour se rendre à l'établissement scolaire et qui représente la variable X regroupée selon trois catégories *courte*, *moyenne* et *longue* (i.e. distance domicile/collège).

On s'intéresse de plus à la variable Y qui représente le niveau scolaire de l'élève. L'objectif est d'étudier l'éventuel impact de la distance domicile/collège sur les résultats. On obtient ainsi le tableau suivant :

	Faible	Moyenne	Elevé
Courte	23	25	79
Moyenne	83	85	55
Longue	102	21	27

- Préciser les variables étudiées ainsi que leur type. Quelle est la population étudiée ? Quelle est la taille de l'échantillon ?  
 Les deux variables sont : la distance parcourue par l'élève pour se rendre à l'établissement scolaire X et son niveau scolaire Y.  
 Les deux variables sont qualitatives.  
 La taille de l'échantillon est : 500 élèves.

- Etablir le tableau complet des effectifs observés en ajoutant les effectifs marginaux.

	Faible	Moyenne	Elevé	Total
Courte	23	25	79	127
Moyenne	83	85	55	223
Longue	102	21	27	150
Total	208	131	161	500

- Calculer le tableau des fréquences observées.

	Faible	Moyenne	Elevé	Total
Courte	0.046	0.05	0.158	0.254
Moyenne	0.166	0.17	0.11	0.446
Longue	0.204	0.042	0.054	0.3
Total	0.416	0.262	0.322	1

- Donner le tableau des profils lignes.

	Faible	Moyenne	Elevé	Total
Courte	0.1811	0.196	0.622	1
Moyenne	0.372	0.381	0.246	1
Longue	0.68	0.14	0.18	1

- Comparer le tableau de profils lignes avec le profil moyen ligne. Que pouvez-vous en conclure sur le lien entre les deux variables ? Justifiez votre réponse.

Il faut comparer les lignes de tableau des profils lignes avec le profil moyen ligne suivant :

0.416	0.262	0.322
-------	-------	-------

On peut remarquer que les profils lignes s'écartent du profil moyen ligne. Par exemple toutes distances confondues, on constate qu'il y a 41,6% d'élève ayant un niveau faible. Or pour les distances courtes, ce pourcentage tombe à 18,11%, et a contrario, pour les distances longues, il augmente à 68%. Ce qui nous laisse conclure que les deux variables sont liées. Conclusion à confirmer avec le test de  $\chi^2$ .

- 6) Quelle est la probabilité que :
- un élève parcourt une distance longue ?  
0.3
  - un élève qui parcourt une longue distance ait un niveau faible ?  
0.68 (Tableau des profils lignes)
  - un élève ait un niveau faible et parcourt une distance moyenne ?

0.166 (Tableau des fréquences)

- 7) En supposant que les deux variables sont indépendantes, calculer l'effectif théorique des élèves de niveau faible et qui parcourent une distance courte. Détailler vos calculs.

L'effectif théorique est :  $(208 \times 127) / 500 = 52.832$

- 8) La distance du chi-deux entre le tableau des effectifs observés et celui des effectifs théoriques est 114.74. Peut-on conclure que les variables sont liées ?

Voici le tableau de seuils de décision

d.d.l.	4	5	6	7	8	9	10	15
Seuil	9.49	11.075	12.59	14.07	15.51	16.92	18.31	24.99

Le d.d.l est :  $(3-1) \times (3-1) = 4$  donc le seuil est 9.49..  $\chi^2 = 114.74 \gg 9.49$  alors les variables sont fortement liées.

Attention, les résultats de ce test ne sont valables que si les effectifs théoriques sont  $> 5$  (ce qui doit être le cas car tous les effectifs marginaux sont élevés)

## Exercice 2

Le tableau ci-après présente une partie des offres locatives de 31 appartements rennais proposés sur le site *leboncoin.fr* au 02/01/2017.

### A- Modèle de prévision du loyer en fonction de la surface

En premier temps, on s'intéresse à étudier la relation entre le loyer Y de ces appartements et leur surface X. Avec le logiciel R nous avons obtenu ce résultat :

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   244.296     54.890   4.451 0.000116 ***
Surface         7.282       1.149   6.339 6.31e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 113.7 on 29 degrees of freedom
Multiple R-squared:  0.5808,    Adjusted R-squared:  0.5664
F-statistic: 40.18 on 1 and 29 DF,  p-value: 6.31e-07

```

- 1) Donner une estimation du coefficient de corrélation entre le loyer et la surface d'un appartement. Est-ce que la surface joue un rôle sur le prix de location des appartements ? Considérez-vous ce rôle comme important ?

Le coefficient de détermination est 0.5808, alors le coefficient de corrélation est  $\pm 0.762$ , les variables sont donc fortement corrélées entre elles. Logiquement, on peut dire que le coefficient de corrélation est 0.762 (et pas -0.762) car les deux variables Surface et Prix de location sont souvent corrélés de sens positive.

- 2) Proposer un modèle permettant de donner la relation entre le loyer des appartements et leur surface.
- X : Surface  
Y : Loyer

$$Y = 7.282 X + 244.296 + \epsilon \text{ (ou bien } Y^{\wedge})$$

$$\text{Loyer} = 7.282 * \text{Surface} + 244.296 + \epsilon$$

- 3) Donner le coefficient de détermination. Interpréter.

$R^2 = 0.5808$ , alors 58% de la variabilité des loyers est expliqué par la droite de régression.

- 4) Un ami qui est en location à Rennes dans un appartement de 30 m<sup>2</sup> m'affirme qu'il paye un loyer de 410 euros. Si je cherche à louer sur Rennes un appartement de même surface :

a) Calculer la valeur prédite du prix de location.

Pour Surface  $X = 30 \text{ m}^2$ , la valeur de Loyer prédite par le modèle est :  $7.282 * 30 + 244.296 = 462.756$

b) Calculer en détaillant la valeur du résidu dans ce cas.

$$\text{Résidu} = \text{Vrai valeur} - \text{Valeur prédite} = 410 - 462.756 = -52.756$$

RÉFÉRENCE	SURFACE (en m <sup>2</sup> )	TYPE	LOYER (en €)	QUARTIER
1068307364	63	T3	660	Atalante Beaulieu
1072846037	65	T3	610	Le Blosne
1072839939	30	T1	410	Patton
1072833908	47	T2	605	Nord St Martin
1072833680	25	T1	400	Centre
1072825556	65	T3	660	Jeanne d'Arc
1072815333	14	T1	341	Sud-Gare
1072807647	41	T2	570	Chézy-Dinan
1072806540	72	T3	790	La Mabilais
1072850534	28	T1	420	Nord St Martin
1072804498	26	T1	420	St Hélier
1072797911	16	T1	310	Beaulieu
1072796804	54	T3	540	Sud-Gare
1072792504	46	T2	600	Cleunay
1072786440	46	T2	610	Nord St Martin
1062080985	62	T2	510	Bréquigny
1072779442	12	T1	320	La Mabilais
1072766364	63	T4	800	Centre
1072765957	32	T2	507	Ste Thérèse
1064945767	71	T3	737	Landry
1072779613	37	T1	500	Bourg-Levesque
1072779761	15	T1	360	Sud-Gare
1064446623	58	T2	1150	Centre
1072756389	66	T3	740	Longchamps
1072745034	48	T2	500	Centre
1072744005	48	T2	570	Poterie
1047805608	65	T3	640	Francisco-Ferrer
1042429291	44	T2	521	Villejean
1067924582	47	T2	585	Villejean
1072733094	33	T1	490	Centre
1036186345	36	T2	710	Beaulieu

## B- Etude du lien entre le loyer et le quartier

On souhaite maintenant savoir si la localisation de l'appartement a un impact sur son loyer. Pour cela on transforme la variable quantitative Loyer en une variable qualitative LoyerB avec 3 modalités suivant les seuils suivants :

LoyerB	
Faible	Loyer < 500
Modéré	$500 \leq \text{Loyer} < 600$
Elevé	Loyer $\geq 600$

- 1) Quelle méthode statistique pouvez-vous mettre en place pour déterminer si les deux variables, LoyerB et Quartier, sont liées ?

Test d'indépendance de Khi-deux.

- 2) Supposons que suite à cette méthode vous avez conclu que les variables sont liées. Vous souhaitez maintenant étudier plus précisément le lien entre les modalités. Pour cela, on effectue une AFC.

a) Que représente le pourcentage affiché sur les axes ?

L'axe 1 représente 58.68% du Khi-deux.

L'axe 2 représente 41.32% du Khi-deux.

100% de la distance du chi-deux est expliquée alors par le plan principal

b) Expliquez pourquoi la somme des deux axes fait exactement 100%.

Car Le nombre des axes de la méthode est le minimum entre le nombre de lignes et le nombre de colonnes moins 1.. Ici la variable LoyerB a le minimum avec 3 modalités, donc le nombre des axes est juste deux et ces deux axes représente alors la totalité de pourcentage de la distance de khi-deux qui est 100%.

c) Interprétez le graphique.

L'axe 1 oppose les quartiers de Villejean et Centre. L'axe 2 oppose Sud Gare et Beaulieu pour les quartiers et Faible et Elevé pour les loyers.

L'angle entre Modéré et Villejean est très faible, on peut donc en déduire que ce quartier a majoritairement des loyers modérés. Dans la même logique, on peut conclure que le quartier Sud Gare présente des loyer faible alors que celui du Centre a des loyers élevés.

d) Quelle autre méthode aurait permis d'étudier le lien entre le quartier et le loyer ?

On aurait pu envisager calculer le rapport de corrélation entre la variable QuartierB et la variable quantitative Loyer (sans transformation). Cela aurait permis d'établir s'il y avait un lien entre les deux variables et sans perdre d'information due au regroupement en classes. L'AFC permet en plus d'établir quelles modalités s'attirent ou se repoussent.

